

Sistemas Multidimensionales

Alumno: MOHAMED DAMOUNE

Práctica 2: Integración de Sistemas - Diseño del Componente ETL



**UNIVERSIDAD
DE GRANADA**

ÍNDICE

GITHUB : <https://github.com/MohammadDamoune/AtletaData>

- 1. Introducción**
- 2. Sección 1 — Data Profiling**
- 3. SECCIÓN 2 — DISEÑO DEL COMPONENTE ETL**
- 4. SECCIÓN 3 — IMPLEMENTACIÓN DEL COMPONENTE ETL CON PENTAHO**
- 5. SECCIÓN 4 — INTEGRACIÓN DE OBJETIVOS EN CONSULTA ANALÍTICA**

1. INTRODUCCIÓN

Esta práctica es la continuación directa de la Práctica 1, en la que se diseñó e implementó el sistema transaccional OLTP de AtletaData, una empresa tecnológica especializada en la monitorización de jugadores de fútbol profesional, junto con su modelo dimensional Data Warehouse y una primera aproximación al componente ETL mediante scripts SQL.

En la Práctica 2 se automatiza ese proceso ETL utilizando Pentaho Data Integration (PDI), también conocido como Kettle. En lugar de ejecutar scripts SQL manualmente, se construyen flujos visuales reutilizables que extraen datos del sistema OLTP de AtletaData, los transforman y los cargan en el Data Warehouse de forma controlada, registrada y reproducible.

La práctica se organiza en cuatro hitos incrementales, cada uno de los cuales añade una nueva sección al presente documento.

2. SECCIÓN 1 — DATA PROFILING

2.1. Introducción al Data Profiling en AtletaData

Antes de construir cualquier proceso ETL, es imprescindible conocer el estado real de los datos en el sistema origen. El Data Profiling es el proceso sistemático de examinar los datos existentes para entender su estructura, comprobar su calidad e identificar problemas que puedan afectar al análisis posterior.

En el caso de AtletaData, este proceso es especialmente crítico por varias razones:

En primer lugar, los datos provienen de sensores físicos colocados en los jugadores que registran métricas cada 5 minutos durante partidos y entrenamientos. Estos sensores pueden generar lecturas erróneas por fallos técnicos, pérdida de señal o movimientos bruscos, lo que puede producir valores imposibles como frecuencias cardíacas de 0 o temperaturas de -99.

En segundo lugar, los datos se integran desde seis esquemas OLTP distintos (oltp_clubes, oltp_jugadores, oltp_partidos, oltp_entrenamientos, oltp_sensor y oltp_medico), cada uno gestionado de forma independiente. Esta fragmentación aumenta el riesgo de inconsistencias en nombres, formatos y referencias entre tablas.

Por último, los datos de AtletaData se utilizan para tomar decisiones críticas sobre la salud y el rendimiento de los jugadores. Un dato erróneo, como un riesgo de lesión calculado sobre una temperatura corporal incorrecta, puede llevar a decisiones médicas equivocadas. La calidad del dato no es solo un requisito técnico, sino una responsabilidad con los jugadores monitorizados.

Por estas razones, el Data Profiling es el primer paso obligatorio antes de diseñar cualquier transformación ETL.

2.2. Dataset Meteorológico — Caso Práctico

Para practicar las técnicas de Data Profiling sobre una fuente de datos externa con problemas reales, el profesor proporciona un dataset meteorológico con observaciones diarias de 10 ciudades españolas entre 2020 y 2024, con un total de 18.282 registros.

Este dataset contiene 9 tipos de anomalías intencionadas que simulan los problemas habituales que se encuentran en sistemas ETL reales. A continuación se documentan los resultados obtenidos tras ejecutar el script de profiling sobre los datos cargados en el schema meteo de la base de datos.

Resultados generales del dataset:

- Total de registros: 18.282
- Rango de fechas: 01/01/2020 — 31/12/2024
- Ciudades distintas detectadas: 27 variantes (correspondientes a 10 ciudades reales)
- Estaciones distintas: 18

2.3. Tabla de Anomalías Detectadas

Tras ejecutar el script 02_profiling_queries.sql sobre el dataset meteorológico, se identificaron las siguientes anomalías:

	Anomalía	Registros afectados	Regla de limpieza
A1	Error de sensor (temp = -99)	15	Sustituir -99 por NULL
A2	Precipitación negativa	8	Sustituir valores negativos por 0.0
A3	Humedad fuera del rango [0, 100]	5	Sustituir por NULL
A4	Nombre de ciudad inconsistente	Múltiples variantes	Normalizar con tabla de equivalencias (ej. "GRANADA" → "Granada")
A5	Temperatura mínima mayor que la máxima	7	Marcar con flag para revisión manual
A6	FK huérfana en estacion_id	20	Registrar en log de errores, asignar estacion_id = -1
A7	Fila completamente nula	3	Eliminar el registro
A8	Duplicado por (fecha, ciudad)	12	Conservar el registro con menor observacion_id
A9	Valor inválido en condicion_climatica	6	Sustituir "N/A", "999", "error", "--" por "Desconocido"

3. SECCIÓN 2 — DISEÑO DEL COMPONENTE ETL

3.1. Integración del Dataset Meteorológico (Caso Guiado)

Como primer caso práctico guiado, se ha integrado un dataset meteorológico con observaciones diarias de 10 ciudades españolas (2020–2024) en el sistema OLAP de AtletaData. Este dataset aporta una dimensión climática que permite responder preguntas de negocio como: ¿aumenta el riesgo de lesión de los jugadores cuando entrenan con temperaturas extremas?

Para realizar esta integración se ha utilizado la transformación `limpieza_meteo_completo.ktr` proporcionada por el profesor, que implementa el flujo ETL completo en tres fases:


Fase 1 — Extracción y limpieza: Se leen los datos crudos de `meteo.observaciones_diarias` y se aplican las 9 reglas de limpieza identificadas en el data profiling: corrección de errores de sensor, normalización de nombres de ciudad, eliminación de filas nulas, deduplicación y gestión de FKs huérfanas.

Fase 2 — Staging: Los datos limpios se almacenan en `staging.observaciones_clean` mediante una carga idempotente (UPSERT por fecha y ciudad). Las FKs huérfanas se registran en `staging.etl_log_fk_huorfanas` para auditoría.

Fase 3 — Carga en DW: Desde staging se realiza un UPSERT final en `olap_snow.dim_clima`, calculando columnas derivadas como `es_dia_lluvia`, `categoria_temperatura`, `anio`, `mes` y `dia_del_anio`.

Resultado de la ejecución:

- `staging.observaciones_clean`: 10.001 filas cargadas
- `olap_snow.dim_clima`: 10.001 filas cargadas en el DW
- `staging.etl_log_fk_huorfanas`: 20 FKs huérfanas registradas



3.2. Diseño del Flujo ETL Propio — AtletaData

2.2.1. Arquitectura ETL elegida

Se ha elegido una arquitectura ETL de tres capas (OLTP → Staging → DW) por las siguientes razones:

La capa de Staging actúa como zona de cuarentena donde los datos se limpian y validan sin afectar al sistema productivo. Si el proceso falla a mitad, el DW queda intacto. Además, permite auditar qué datos se procesaron y cuándo, y desacopla el ritmo de extracción del ritmo de carga.

Se ha elegido la estrategia **ETL** (transformar antes de cargar) en lugar de **ELT** porque AtletaData trabaja con un Data Warehouse relacional en PostgreSQL. La estrategia **ELT** sería más adecuada en entornos Big Data basados en Data Lakes en la nube, que no es nuestro caso.

La estrategia de carga elegida es **Full Load**, ya que el volumen de datos de jugadores y clubes es reducido (75 jugadores, 3 clubes) y no justifica la complejidad de una carga incremental.

3.2.2. Diagrama de arquitectura (describir en Word con una tabla o flecha)

OLTP (PostgreSQL)	STAGING	DW (OLAP)
oltp_jugadores → oltp_clubes	staging.stg_jugadores _clean	→ olap.dim_jugador (actualizado)

3.2.3. Diagrama del flujo de transformaciones

El flujo ETL propio consta de 5 pasos encadenados:

Paso	Nombre	Tipo	Descripción
1	Leer jugadores OLTP	Table Input	Lee oltp_jugadores.jugadores JOIN oltp_clubes.clubes
2	Filtrar solo activos	Filter Rows	Descarta jugadores con estado ≠ 'activo'
3	Normalizar texto	String Operations	Normaliza nombre y apellidos a Title Case
4	Calcular edad	Calculator	Calcula edad a partir de fecha_nacimiento
5	Cargar en staging	Insert/Update	UPSERT en staging.stg_jugadores_clean por id_jugador

3.2.4. Justificación de decisiones de diseño

¿Por qué ETL y no ELT? AtletaData usa PostgreSQL como DW relacional. La estrategia ELT requiere un motor de procesamiento distribuido (Spark, BigQuery) que no está disponible en este entorno. ETL con Pentaho es la opción más adecuada.

¿Carga incremental o Full Load? Full Load. La tabla de jugadores tiene solo 75 registros y cambia raramente. El coste de implementar una carga incremental (gestión de SCD, timestamps de modificación) no está justificado para este volumen.

4. SECCIÓN 3 — IMPLEMENTACIÓN DEL COMPONENTE ETL CON PENTAHO

4.1. Flujo ETL implementado — etl_jugadores_atletadata.ktr

Se ha implementado una transformación Pentaho (.ktr) que extrae los datos de jugadores del sistema OLTP de AtletaData, filtra los jugadores activos y los carga en el área de Staging.



4.2. Configuración de cada paso

Paso	Tipo	Configuración
Entrada Tabla	Table Input	Lee oltp_jugadores.jugadores JOIN oltp_clubes.clubes. Calcula edad con DATE_PART('year', AGE(fecha_nacimiento)). Conexión: atletadata
Filtrar filas	Filter Rows	Condición: estado = 'activo'. Solo pasan jugadores activos al siguiente paso
Insertar / Actualizar	Insert/Update	UPSERT en staging.stg_jugadores_clean. Clave: id_jugador. Actualiza todos los campos si el jugador ya existe

4.3. Resultado de la ejecución

Paso	Leídos	Escritos	Errores
Entrada Tabla	75	75	0
Filtrar filas	75	75	0
Insertar/Actualizar	75	75	0

4.4. Catálogo de ficheros .ktr

Fichero .ktr	Propósito	Entrada	Salida
limpieza_meteo_completo.ktr	ETL guiado: limpieza dataset meteorológico	meteo.observaciones_dias	staging.observaciones_clean / olap_snow.dim_clima
etl_jugadores_atletadata.ktr	ETL propio: extracción y limpieza de jugadores AtletaData	oltp_jugadores.jugadores	staging.stg_jugadores_clean

5. SECCIÓN 4 — INTEGRACIÓN DE OBJETIVOS EN CONSULTA ANALÍTICA

5.1. Descripción del flujo

En este hito se ha implementado una transformación Pentaho (.ktr) que integra datos del sistema OLAP con un fichero CSV externo que contiene los objetivos de rendimiento por posición. El objetivo es generar un informe final que compare el rendimiento real de los jugadores con los objetivos marcados por la dirección.

4.2. Configuración de cada paso

Paso	Tipo	Configuración
Entrada Tabla	Table Input	Lee km_acumulados y velocidad medios por posición desde olap.fact_rendimiento JOIN olap.dim_jugador. Conexión: atletadata
CSV file input	CSV File Input	Lee objetivos_jugadores.csv con las columnas posicion, objetivo_km y objetivo_velocidad. Delimitador: ;
Búsqueda en flujo de datos	Stream Lookup	Cruza ambos flujos por el campo posicion. Recupera objetivo_km y objetivo_velocidad del CSV
Añadir constantes	Add Constants	Añade una constante numérica con valor 100 para calcular porcentajes
Calculadora	Calculator	Calcula ratio_km, pct_km_cumplido, ratio_vel y pct_velocidad_cumplida mediante operaciones A/B y A*B
Ordenar filas	Sort Rows	Ordena el resultado por km_medio de forma descendente
Insertar / Actualizar	Insert/Update	Guarda los resultados en staging.resultados_analisis. Clave: posicion
Salida Fichero de Texto	Text File Output	Exporta el informe final en formato CSV con separador ;

