SISTEMAS MULTIDIMENSIONALES

PRACTICA 1

Diseno de Sistemas Multidimensionales

De OLTP a Data Warehouse

ALUMNO : MOHAMED DAMOUNE

EMAIL : ks9163694@correo.ugr.es

GitHub : https://github.com/MohammadDamoune/AtletaData

INDICE DE CONTENIDOS

1. Analisis del Sistema Real (OMS Global Health Observatory)
   1.1. Objetivo del negocio
   1.2. Fuentes de datos
   1.3. Dimensiones principales
   1.4. Hechos y metricas clave
   1.5. Tecnologia utilizada
   1.6. Preguntas de negocio

2. Descripcion de AtletaData
   2.1. Contexto de negocio
   2.2. Fuentes de datos OLTP

3. Preguntas de Negocio y Decisiones Estrategicas
   3.1. Preguntas de negocio
   3.2. Decisiones estrategicas

4. Modelo OLAP Conceptual
   4.1. Bus Matrix
   4.2. Diagramas estrella

5. Diseno de Fuentes de Datos Transaccionales (Hito 2)
   5.1. Arquitectura de esquemas OLTP
   5.2. Diagramas ER
   5.3. Scripts DDL
   5.4. Poblacion de datos (DML)

6. Data Warehouse Dimensional (Hito 3)
   6.1. Mapeo OLTP a OLAP
   6.2. Dimensiones
   6.3. Tablas de hechos
   6.4. ETL basico
   6.5. Modelo copo de nieve

7. Benchmarking (Hito 4)

1. Analisis del Sistema Real

El sistema que estamos estudiando es el de la OMS (Organización Mundial de la Salud), llamado GHO Global Health Observatory.

Este sistema sirve para ver datos de solud de todo el mundo.
Lo usan gobiernos y médicos para tomar decisiones importantes.

1.1. Objetivo del negocio

El objetivo es dar información sobre muertes enfermedades en el mundo , con estos datos los países pueden :
- Ver que enfermedades son mas graves.
- Comparar entre países.
- decidir donde invertir denero en salud.

Usuarios principales del sistema son : Gobiernos , Medicos , Investigadores.

1.2. Fuentes de datos

Los datos vienen de diferentes sitios:

Fuente	Informacion que aporta
Registros de cada pais	Muertes registradas por causa, edad y sexo en cada pais
Ministerios de Salud	Estadisticas sanitarias oficiales de cada gobierno
Estimaciones OMS	Datos calculados para paises sin registro completo
ONU y organismos asociados	Datos demograficos, poblacion y contexto economico
Clasificacion Internacional de Enfermedades (CIE-11)	Estandar para codificar causas de muerte

1.3. Dimensiones principales con jerarquias

Dimension	Jerarquia
Tiempo	Decada → Ano → (datos disponibles: 2000-2021)
Geografia	Mundo → Region OMS → Pais
Enfermedad	Categoria → Grupo → Enfermedad especifica
Grupo de edad	Todas las edades → Grupo (0-4, 5-14, 15-29, 30-49, 50-59, 60-69, 70+)
Sexo	Total → Hombre / Mujer
Nivel economico	Mundial → Pais alto / medio-alto / medio-bajo / bajo

Ejemplo : Si queremos ver muertes por cancer en Marruecos entre 2010 y 2020 por sexo , estamos usando varias dimensiones a la vez.

1.4. Hechos y metricas clave

Metrica	Descripcion
Numero de muertes	Total de fallecimientos por causa, pais y ano
Tasa de mortalidad	Muertes por cada 100.000 habitantes (permite comparar paises)
Porcentaje del total	Que porcentaje del total de muertes representa esa causa
Tendencia porcentual	Variacion porcentual entre 2000 y 2021
Anos de vida perdidos	Impacto de la enfermedad considerando la edad de muerte

1.5. Tecnologia utilizada

Componente	Tecnologia
Plataforma de datos	Global Health Observatory (data.who.int)
Visualizacion	Dashboards interactivos con mapas, graficos y tablas
Descarga de datos	Archivos CSV y API REST publica
Estandar de enfermedades	Clasificacion Internacional de Enfermedades CIE-11
Acceso	Publico y gratuito, sin registro

1.6. Preguntas de negocio que resuelve

- ¿Cual es la principal causa de muerte en Espana en 2021?
- ¿Como ha evolucionado la mortalidad por diabetes entre 2000 y 2021?
- ¿En que region del mundo mueren mas personas de cancer?
- ¿Como varia la mortalidad cardiovascular entre paises de ingresos altos y bajos?
- ¿Que enfermedades han aumentado mas su mortalidad en los ultimos 20 anos?

2. Descripcion de AtletaData

2.1. Contexto de negocio

AtletaData es una empresa tecnologica espanola especializada en la monitorizacion de jugadores de futbol profesional.

Su producto combina dos cosas :
un sensor fisico que se coloca en la espalda del jugador dentro de su equipacion, con una plataforma web donde el equipo tecnico puede consultar todos los datos recogidos en tiempo real.

El sensor funciona tanto en partidos como en entrenamientos, recogiendo datos continuamente y enviandolos a la plataforma.

Actualmente da servicio a 3 clubes de La Liga: Real Madrid CF, FC Barcelona y Atletico de Madrid, con un total de 75 jugadores monitorizados.

Datos que recoge el sensor

Datos de salud:

- Frecuencia cardiaca
- Temperatura corporal
- Nivel de fatiga muscular
- Equilibrio corporal al correr
- Riesgo de lesion calculado automaticamente

Datos de rendimiento:

- Kilometros recorridos
- Velocidad maxima
- Numero de sprints
- Aceleraciones y frenadas

Usuarios de la plataforma

Perfil	Objetivo principal
Medico del club	Vigila la salud del jugador y recibe alertas si hay riesgo de lesion
Preparador fisico	Analiza el rendimiento fisico y ajusta las cargas de entrenamiento
Entrenador principal	Toma decisiones tacticas basadas en el estado fisico real del equipo

2.2. Fuentes de datos OLTP

Cada departamento de AtletaData tiene su propia base de datos transaccional. Estas son las fuentes que se integran en el Data Warehouse:

Departamento	Esquema OLTP	Que guarda	Volumen aprox.
Sensor	oltp_sensor	Datos del sensor cada 5 minutos: frec. cardiaca, temperatura, fatiga, equilibrio, posicion	Miles de registros por partido
Medico	oltp_medico	Bajas medicas, motivos, fechas y medico responsable	1 baja por lesion por jugador
Jugadores	oltp_jugadores	Perfil de cada jugador: nombre, edad, posicion, club, nacionalidad	25 jugadores por club
Partidos	oltp_partidos	Partidos, alineaciones, cambios y tarjetas	Hasta ahora 10 partidos por club
Entrenamientos	oltp_entrenamientos	Sesiones: fecha, duracion, tipo, intensidad	Hasta ahora 15 sesiones por club
Clubes	oltp_clubes	Clubes clientes de AtletaData	Hasta ahora contratamos 3 clubes activos

3. Preguntas de Negocio y Decisiones Estrategicas

3.1. Preguntas de negocio

- Estas son las 5 preguntas clave que el Data Warehouse de AtletaData debe poder responder:

Pregunta 1 — Fatiga en el partido (Medico + Preparador fisico)

En que minuto del partido se dispara la fatiga de cada jugador y como varia segun el rival o el tipo de competicion?

Pregunta 2 — Riesgo de lesion semanal (Medico)

Que jugadores tienen mayor riesgo de lesion esta semana, basandose en sus datos de fatiga, temperatura y equilibrio corporal de los ultimos partidos y entrenamientos?

Pregunta 3 — Evolucion de salud en la temporada (Medico + Entrenador)

Como ha evolucionado la salud general de un jugador a lo largo de la temporada? Mejora, empeora o estable?

Pregunta 4 — Evolucion de velocidad (Preparador fisico)

Como ha evolucionado la velocidad maxima de cada jugador durante la temporada y en que momento del ano esta en su mejor forma fisica?

Pregunta 5 — Equilibrio corporal (Medico + Preparador fisico)

Que jugadores muestran desequilibrio corporal al correr y que plan de entrenamiento personalizado necesitan para corregirlo antes de que se convierta en lesion?

3.2. Decisiones estrategicas

Decision 1 — Organizacion semanal de entrenamientos

Cada semana, antes de planificar los entrenamientos, el entrenador consulta el estado fisico de todos los jugadores en la plataforma. Con los datos de fatiga y kilometros recorridos y velocidad del ultimo partido, decide que jugadores pueden entrenar fuerte y cuales necesitan recuperacion y cuales deben descansar completamente.

Decision 2 — Baja preventiva antes de que la lesion empeore

El medico del club revisa diariamente las alertas del sistema. Cuando un jugador acumula seniales de riesgo durante varios dias seguidos (temperatura elevada, desequilibrio corporal, fatiga alta), el medico decide darle de baja preventiva antes de que la lesion se haga visible y sea mas grave.

4. Modelo OLAP Conceptual

4.1. Bus Matrix

La Bus Matrix es una tabla que junta :

Los procesos de negocio (tablas de hechos) con Las diminciones .

Muestra que dimensiones usa cada tabla de hechos.

Proceso de negocio	Tiempo	Jugador	Club	Partido	Entrenamiento
Fact_Salud	X	X	X	X	X
Fact_Rendimiento	X	X	X	X	X
Fact_LesionRiesgo	X	X	X		

Nota : **Fact_LesionRiesgo** no tiene Dim_Partido ni Dim_Entrenamiento porque el riesgo se calcula acumulando datos de toda una semana, no de un evento concreto.

4.2. Diagramas estrella

A continuacion se presentan los tres diagramas estrella del modelo dimensional de AtletaData. Cada diagrama muestra la tabla de hechos en el centro rodeada por sus dimensiones.

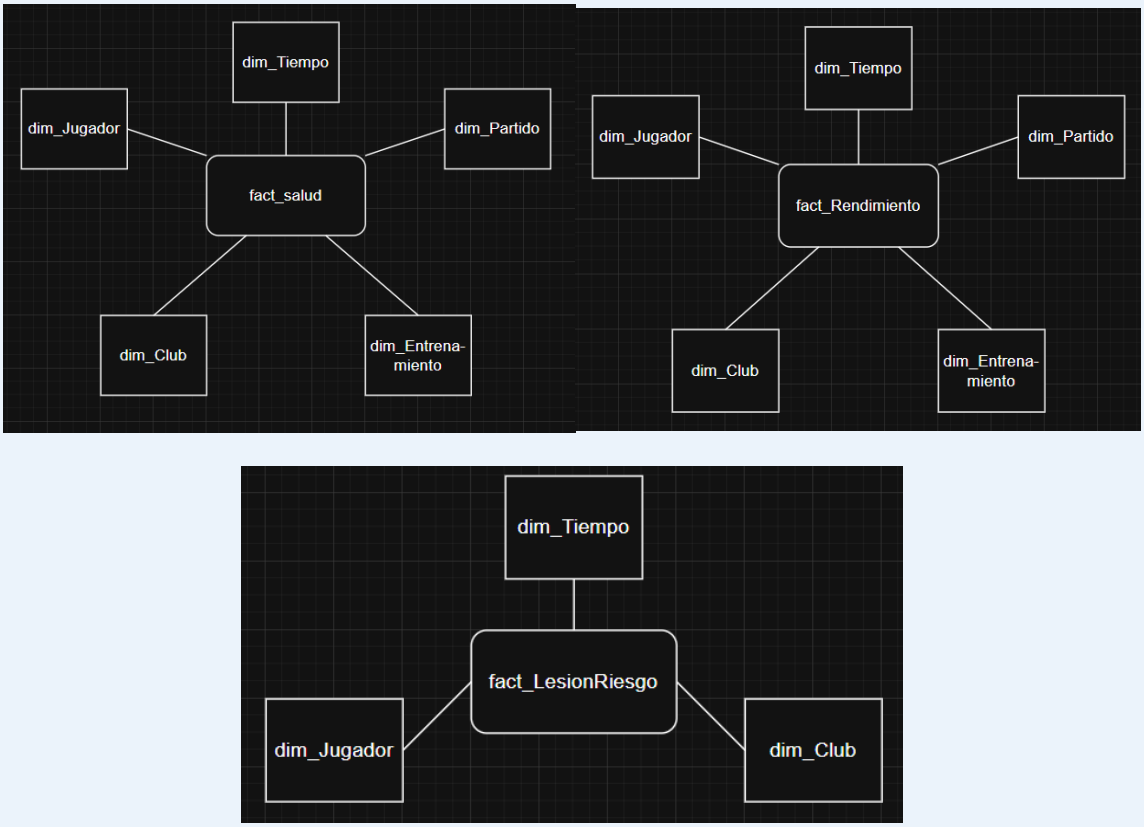

5. Diseno de Fuentes de Datos Transaccionales (Hito 2)

5.1. Arquitectura de esquemas OLTP

En el mundo real, los sistemas operacionales viven en bases de datos distintas. Para simular este entorno, se han creado esquemas distintos dentro de la misma base de datos AtletaData, proporcionando independencia logica entre departamentos.

En en mondo real , cada parte del sistema usa su propia base de datos , en este proyecto vamos a hacer lo mismo , pero dentro de una sola base de datos usando esquemas diferentes.

Esquema	Tablas principales	Descripcion
oltp_clubes	clubes	Clubes clientes de AtletaData con sus datos de contrato
oltp_jugadores	jugadores	Perfil completo de cada jugador por club
oltp_partidos	partidos, alineaciones, cambios, tarjetas	Informacion de partidos y participacion de jugadores
oltp_entrenamientos	entrenamientos	Sesiones de entrenamiento con tipo e intensidad
oltp_sensor	sensor_salud, sensor_rendimiento	Datos bdel sensor fisico cada 5 minutos
oltp_medico	bajas	Historial de bajas medicas y lesiones

5.2. Diagramas ER

Los diagramas ER de cada esquema OLTP están disponibles en el repositorio de GitHab del proyecto. https://github.com/MohammadDamoune/AtletaData
diagrama muestra las tablas y relaciones entre ellas (claves foraneas).

5.3. Scripts DDL

los scripts de creacion de los esquemas y tablas principales del sistema OLTP. El script completo esta disponible en el repositorio del proyecto (file Crear_esquema_OLTP.sql).

https://github.com/MohammadDamoune/AtletaData

Los scripts DDL que siven para crear los esquemas y tablas del sistema OLTP, tamnbien están en el reposirorio de GitHub del proyecto (file generar_datos.py).

Ejmplo de Creacion de esquemas

```
CREATE SCHEMA oltp_clubes;
CREATE SCHEMA oltp_jugadores;
CREATE SCHEMA oltp_partidos;
CREATE SCHEMA oltp_entrenamientos;
CREATE SCHEMA oltp_sensor;
CREATE SCHEMA oltp_medico;
```

5.4. Poblacion de datos (DML)

Los datos sinteticos se generaron mediante un script Python usando psycopg2. Se poblaron los sistemas con datos reales de jugadores de La Liga temporada 2024-25.

Tabla	Registros insertados
oltp_clubes.clubes	3 clubes (Real Madrid, Barcelona, Atletico)
oltp_jugadores.jugadores	75 jugadores (25 por club)
oltp_partidos.partidos	30 partidos (10 por club)
oltp_entrenamientos.entrenamientos	45 sesiones (15 por club)
oltp_partidos.alineaciones	Aprox. 330 registros
oltp_partidos.cambios	Aprox. 90 registros
oltp_partidos.tarjetas	Variable (20% probabilidad por partido)
oltp_medico.bajas	Variable (40% probabilidad por partido)
oltp_sensor.sensor_salud	Miles de registros (cada 5 minutos por jugador)
oltp_sensor.sensor_rendimiento	Miles de registros (cada 5 minutos por jugador)

Ejemplo de datos insertados

```
-- Ejemplo de insercion de clubes
INSERT INTO oltp_clubes.clubes
  (nombre_club, pais, ciudad, liga, num_jugadores, fecha_contrato, activo)
VALUES
  ('Real Madrid CF', 'Espana', 'Madrid', 'La Liga', 25, '2023-07-01', TRUE),
  ('FC Barcelona', 'Espana', 'Barcelona', 'La Liga', 25, '2023-07-01', TRUE),
  ('Atletico de Madrid', 'Espana', 'Madrid', 'La Liga', 25, '2023-08-01', TRUE);
```

6. Data Warehouse Dimensional (Hito 3)

6.1. De OLTP a OLAP

Antes de crear el Data Warehouse se identifico que tablas del OLTP son candidatas a dimension y cuales a hechos, usando los criterios de la metodologia Kimball:

Antes de crear Data Warehouse hay que decidir que tablas son DIMENCIONES y que tablas son HECHOS

Tabla OLTP	Tipo	Tabla DW	Justificacion
oltp_clubes.clubes	Dimension	dim_club	Atributos descriptivos del club, baja volatilidad
oltp_jugadores.jugadores	Dimension	dim_jugador	Atributos del jugador, cambia lentamente
oltp_partidos.partidos	Dimension	dim_partido	Contexto del evento deportivo
oltp_entrenamientos.entrenamientos	Dimension	dim_entrenamiento	Contexto de la sesion de entrenamiento
Calculado desde fechas	Dimension	dim_tiempo	Jerarquia temporal para analisis
oltp_sensor.sensor_salud	Hecho	fact_salud	Metricas numericas de salud minuto a minuto
oltp_sensor.sensor_rendimiento	Hecho	fact_rendimiento	Metricas fisicas de rendimiento minuto a minuto
Agregado semanal de sensor_salud	Hecho	fact_lesion_riesgo	Metricas de riesgo agregadas por semana

6.2. Dimensiones

Se crearon 5 dimensiones en un sistema OLAP . Estas dimensiones se usan en varias tablas de datos al mismo tiempo , y eso hace que todos los análisis usen la misma información y no haya diferencias entre ellos .

dim_tiempo

Centraliza todos los niveles de la jerarquia temporal. Permite analizar desde temporada hasta minuto especifico.

Columna	Tipo	Descripcion
tiempo_sk	SERIAL PK	Surrogate key autoincremental
fecha	DATE	Fecha del evento
anio	INT	Ano extraido de la fecha

Columna	Tipo	Descripcion
mes	INT	Mes (1-12)
nombre_mes	VARCHAR	Nombre del mes en texto
trimestre	INT	Trimestre (1-4)
semana	INT	Semana del ano
temporada	VARCHAR	Temporada (ej. 2024-25)

dim_jugador

Contiene todos los atributos descriptivos del jugador, desnormalizados incluyendo el nombre del club directamente para evitar joins adicionales.

Columna	Tipo	Descripcion
jugador_sk	SERIAL PK	Surrogate key
jugador_id	INT	ID original del OLTP
nombre_completo	VARCHAR	Nombre y apellidos concatenados
edad	INT	Edad calculada automaticamente
posicion	VARCHAR	Posicion en el campo
dorsal	INT	Numero de dorsal
nombre_club	VARCHAR	Nombre del club (desnormalizado)
liga	VARCHAR	Liga en la que juega

dim_club

Contiene los datos descriptivos de cada club cliente de AtletaData.

dim_partido

Contexto de cada partido: competicion, jornada, si fue local o visitante, duracion y temporada.

dim_entrenamiento

Contexto de cada sesion de entrenamiento: tipo (fisico, tactico, recuperacion, tecnico, mixto), intensidad y duracion.

6.3. Tablas de hechos

fact_salud

Granularidad: 1 fila por jugador por minuto por partido o entrenamiento. Contiene las metricas de salud recogidas por el sensor.

Columna	Tipo	Descripcion
salud_sk	SERIAL PK	Surrogate key
tiempo_sk	INT FK	Referencia a dim_tiempo
jugador_sk	INT FK	Referencia a dim_jugador
club_sk	INT FK	Referencia a dim_club
partido_sk	INT FK	Referencia a dim_partido (NULL si entrenamiento)
entrenamiento_sk	INT FK	Referencia a dim_entrenamiento (NULL si partido)
minuto	INT	Minuto del evento
frec_cardiaca	INT	Frecuencia cardiaca en ppm
temperatura	NUMERIC	Temperatura corporal en grados Celsius
fatiga	NUMERIC	Nivel de fatiga (0-10)
equilibrio	NUMERIC	Desequilibrio corporal (0-1)
riesgo_lesion	NUMERIC	Probabilidad de lesion (0-100)

fact_rendimiento

Granularidad: 1 fila por jugador por minuto por partido o entrenamiento. Contiene las metricas fisicas de rendimiento recogidas por el sensor.

Columna	Tipo	Descripcion
rendimiento_sk	SERIAL PK	Surrogate key
tiempo_sk / jugador_sk / club_sk	INT FK	Referencias a dimensiones
partido_sk / entrenamiento_sk	INT FK	Contexto del evento
minuto	INT	Minuto del evento
km_acumulados	NUMERIC	Kilometros recorridos hasta ese minuto
velocidad	NUMERIC	Velocidad en km/h
num_sprints	INT	Numero de sprints realizados
aceleraciones	INT	Numero de aceleraciones
frenadas	INT	Numero de frenadas bruscas

fact_lesion_riesgo

Granularidad: 1 fila por jugador por semana. Agrega los datos del sensor calculando medias y maximos para identificar tendencias de riesgo acumulado.

6.4. ETL basico

El proceso ETL (Extract, Transform, Load) extrae los datos de los esquemas OLTP, los transforma calculando las metricas necesarias y los carga en el esquema OLAP. Se implemento mediante sentencias SQL INSERT INTO ... SELECT que realizan las tres fases en una sola operacion.

Ejemplo ETL — Carga de dim_tiempo

```
INSERT INTO olap.dim_tiempo (fecha, anio, mes, nombre_mes, trimestre, semana,
temporada)
SELECT DISTINCT
  fecha::DATE,
  EXTRACT(YEAR FROM fecha)::INT,
  EXTRACT(MONTH FROM fecha)::INT,
  TO_CHAR(fecha, 'TMMonth'),
  EXTRACT(QUARTER FROM fecha)::INT,
  EXTRACT(WEEK FROM fecha)::INT,
  '2024-25'
FROM (
  SELECT fecha_partido AS fecha FROM oltp_partidos.partidos
  UNION
  SELECT fecha_sesion AS fecha FROM oltp_entrenamientos.entrenamientos
) fechas;
```

6.5. Modelo copo de nieve

Para convertir el modelo estrella a copo de nieve se divide una dimension en varias tablas relacionadas, reduciendo la redundancia a costa de mas joins en las consultas. Se muestra a continuacion como quedaria dim_jugador en version copo de nieve:

Esto hace que haya menos datos repetidos , pero las consultas necesitan mas uniones(joins) por lo que son mas complejas y cogen un poco de tiempo.

A cotinuacion se muestran como quedaría la tabla dim_jugador en versión copo de nieve.

Aspecto	Estrella	Copo de nieve
Estructura	Todo en una tabla plana	Dimension dividida en varias tablas
Velocidad consultas	Mas rapido (menos joins)	Mas lento (mas joins necesarios)
Espacio en disco	Mas espacio (datos repetidos)	Menos espacio (sin redundancia)
Mantenimiento	Mas sencillo	Mas complejo
Cuando usar	Siempre por defecto	Solo con millones de registros

Script — dim_jugador en version copo de nieve

```
-- Tabla de posiciones (extraida de dim_jugador)
CREATE TABLE olap.dim_posicion (
  posicion_sk     SERIAL PRIMARY KEY,
  nombre_posicion VARCHAR(50)
);

-- Tabla de nacionalidades (extraida de dim_jugador)
CREATE TABLE olap.dim_nacionalidad (
  nacionalidad_sk      SERIAL PRIMARY KEY,
  nombre_nacionalidad  VARCHAR(50)
```

```
);

-- dim_jugador en copo de nieve (con claves a tablas separadas)
CREATE TABLE olap.dim_jugador_snow (
  jugador_sk      SERIAL PRIMARY KEY,
  jugador_id      INT,
  nombre          VARCHAR(100),
  apellidos        VARCHAR(100),
  edad             INT,
  dorsal           INT,
  posicion_sk      INT REFERENCES olap.dim_posicion(posicion_sk),
  nacionalidad_sk  INT REFERENCES olap.dim_nacionalidad(nacionalidad_sk),
  club_sk          INT REFERENCES olap.dim_club(club_sk)
);
```

En el modelo estrella la tabla dim_jugador tiene los campos posicion y nacionalidad como texto repetido en cada fila.
En el copo de nieve esos valores no se repiten en cada fila y se extraen a tablas propias y dim_jugador solo guarda una clave numerica que apunta a ellas, eliminando la redundancia.

7. Benchmarking (Hito 4)

las consultas ensan en repositorty de GitHub (file Benchmarking.py)
https://github.com/MohammadDamoune/AtletaData
resultado de Benchmarking es :

```
================================================================================
Consulta                          OLTP(ms)   OLAP(ms)     Mejora
================================================================================
Q1 Fatiga por minuto                 42.46       22.1 +     48.0%
Q2 Riesgo lesion semanal              95.7        2.1 +     97.8%
Q3 Evolucion salud mensual           87.85      90.04      -2.5%
Q4 Velocidad maxima mensual          84.25       68.1 +     19.2%
Q5 Desequilibrio corporal             34.5        6.7 +     80.6%
================================================================================

Detalle por consulta:

Q1 Fatiga por minuto
  OLTP — media: 42.46ms  min: 39.0ms  max: 60.64ms  desv: 6.69ms
  OLAP — media: 22.1ms  min: 19.0ms  max: 30.02ms  desv: 3.52ms

Q2 Riesgo lesion semanal
  OLTP — media: 95.7ms  min: 88.0ms  max: 115.0ms  desv: 8.56ms
  OLAP — media: 2.1ms  min: 1.0ms  max: 4.0ms  desv: 0.74ms

Q3 Evolucion salud mensual
  OLTP — media: 87.85ms  min: 76.0ms  max: 131.81ms  desv: 18.26ms
  OLAP — media: 90.04ms  min: 64.0ms  max: 172.11ms  desv: 43.2ms

Q4 Velocidad maxima mensual
  OLTP — media: 84.25ms  min: 79.02ms  max: 91.0ms  desv: 4.84ms
  OLAP — media: 68.1ms  min: 44.0ms  max: 87.0ms  desv: 16.87ms

Q5 Desequilibrio corporal
  OLTP — media: 34.5ms  min: 32.0ms  max: 49.0ms  desv: 5.15ms
  OLAP — media: 6.7ms  min: 4.0ms  max: 8.0ms  desv: 1.5ms

Benchmark completado
```